

并行与分布式导论 — Lab2：昇腾 NPU 微基准测试设计

截止日期：2026年6月20日 23:59
提交方式：将 lab2_学号_姓名.zip 提交至教学网

1. 背景


昇腾（Ascend）是华为自研的 AI 处理器，基于 DaVinci 架构设计，其微架构概览见教学网：TensorOJ平台与芯片算子开发.pdf 第8页。

芯片架构

(2) 分离架构

- 包含两种核心
 - Vector核
 - Scalar和Vector计算单元
 - Cube核
 - Scalar和Cube计算单元

昇腾910B计算卡：
分离架构，20AIC+40AIV



本实验的核心任务是：

设计 μ bench：通过设计并运行微基准测试程序，在昇腾计算卡上实测各微架构组件的性能参数（延迟、带宽、吞吐率等）

2. 实验环境

本实验围绕昇腾910B计算卡进行，其关键规格如下：

项目	规格
架构	DaVinci
AI Core 数量	根据卡型号不同（通常 20+ 个）
计算单元	Scalar Unit / Vector Unit / Cube Unit
片上存储	L1 Buffer / L0A / L0B / L0C
片外内存	HBM（高带宽内存）
指令集	自研 Ascend 指令集

3. 参考方案

3.1 Accel-Sim μ bench 方法论

本实验的 μ bench 设计思路参考 [Accel-Sim GPU Microbenchmark](#) 套件。其核心思想是：

- 1. **逐组件隔离测量**：每次只让一个硬件单元工作，排除其他单元干扰
- 2. **参数化控制**：通过改变数据规模、循环次数等参数，观测性能变化规律
- 3. **从简单推导复杂**：先测原子操作延迟，再测流水线深度，最后组合建模

3.2 常用 μ bench 设计模式

模式	用途	方法
Pointer Chasing	测量存储访问延迟	构造指针链表，通过随机访问消除缓存预取效应
Streaming	测量带宽	发起大量连续数据传输，逐步增大数据量直到带宽饱和
Dependency Chain	测量运算单元延迟	构造有数据依赖的指令链，迫使串行执行以暴露单条指令延迟

4. 实验任务：设计 μ bench，测量架构参数

4.1 什么是 μ bench？

μ bench（Microbenchmark，微基准测试）是一种极简的、针对特定硬件单元的可控测试程序。它只执行单一类型的操作（如纯向量加法、纯数据搬运），排除了无关因素的干扰，从而精确测量某个微架构组件的性能参数。

4.2 需要测量什么？

参考背景中给出的 DaVinci 微架构图，你需要为以下组件设计对应的 μ bench。以下参数为必测项，每个参数都将在评分中作为独立考核点：

4.2.1 Scalar Unit（标量单元）

参数编号	参数名称	描述	单位
S1	标量算术指令延迟	单条标量加法指令从发射到完成的周期数	cycles
S2	标量单元吞吐率	单位时间内可完成的标量加法运算次数（考虑流水线深度）	ops/cycle
S3	标量访存延迟	标量 Load/Store 指令的访问延迟	cycles

4.2.2 Vector Unit（向量单元）

参数编号	参数名称	描述	单位
V1	FP32 向量加法延迟	单条 FP32 向量加法指令从发射到完成的周期数	cycles
V2	FP32 向量乘法延迟	单条 FP32 向量乘法指令从发射到完成的周期数	cycles
V3	向量单元吞吐率	单位时间内可完成的向量加法运算次数	ops/cycle
V4	向量单元流水线深度	向量单元能同时容纳的处于不同阶段的指令数	条
V5	向量寄存器访问延迟	向量寄存器读/写延迟（区分读写）	cycles

4.2.3 Cube Unit（矩阵乘单元）

参数编号	参数名称	描述	单位
C1	矩阵乘延迟（单 tile）	单个最小 tile（如 16×16） 矩阵乘法从发射到完成的周期数	cycles
C2	矩阵乘吞吐率	单位时间内可完成的 MAC 操作数（TFLOPS）	MAC/s
C3	矩阵乘流水线深度	Cube 单元支持的最大流水线并行度	条
C4	L0A/L0B/L0C 访问延迟	Cube 单元专用缓冲区（L0A/L0B/L0C）的读写延迟	cycles
C5	不同规模矩阵乘延迟缩放关系	矩阵规模（M/N/K）增大时矩阵乘延迟的增长规律 （折线图）	—

4.2.4 MTE（Memory Transfer Engine，数据搬运单元）

参数编号	参数名称	描述	单位
M1	L1 Buffer 读取带宽	从 L1 Buffer 读取数据的峰值带宽	GB/s
M2	L1 Buffer 写入带宽	向 L1 Buffer 写入数据的峰值带宽	GB/s
M3	L0A 带宽	L0A 缓冲区读写带宽	GB/s
M4	L0B 带宽	L0B 缓冲区读写带宽	GB/s
M5	L0C 带宽	L0C 缓冲区读写带宽	GB/s
M6	DDR/HBM 访存延迟	从片外内存读取数据的首字延迟	cycles

参数编号	参数名称	描述	单位
M7	各级 Buffer 容量	L1/L0A/L0B/L0C 各自的实际可用容量	KB/MB
M8	数据搬运启动开销	MTE 启动一次 DMA 传输的固定开销	cycles

参数汇总：以上共计 4 大类、21 个参数（S1–S3, V1–V5, C1–C5, M1–M8）。每个参数均需独立的 μ bench 进行测量，并在报告中提供测量方法、原始数据和分析。

4.3 如何设计 μ bench？

μ bench 不限制实现方式（C++ Kernel、Python 脚本等均可），核心原则：

- 1. **隔离性：**一次只测一种操作，避免互相干扰
- 2. **可控性：**能精确控制操作规模（数据量、循环次数）
- 3. **可重复性：**多次运行取平均或中位数，排除噪声
- 4. **可验证性：**结果应有合理的物理意义（如带宽不超过理论峰值）

每个 μ bench 需要撰写简短说明：测什么、怎么测、为什么这样设计。

5. 评分标准

本实验评分基于两个方面： μ bench 完成度和测量准确度。

5.1 μ bench 完成度（42 分）

每个参数需要提供一个**独立可运行的 μ bench** 来测量。评分依据 μ bench 是否具备完整的测量方案：

单个 μ bench 的评分标准（每个参数 2 分）：

完成等级	得分	判定标准
完整实现	2 分	μ bench 代码可运行；测量方法合理（满足隔离性、可控性）； 产出测量结果并有原始数据
部分实现	1 分	有 μ bench 设计思路说明，但代码不可运行或测量方法有明显缺陷
未实现 / 仅文字描述	0 分	未提供 μ bench 代码，或仅有文字说明而无实际测量

21 个参数满分 42 分。建议优先完成核心参数（S1、V1–V2、C1、M1–M2），再逐步覆盖全部参数。
注意： μ bench 完成度与 5.2 节的准确度是独立评分的。即使测量结果不准确，只要 μ bench 设计合理且可运行，仍可获得本项的分数。

5.2 参数测量准确度（42 分）

对 4.2 节中列出的 21 个参数（S1–S3, V1–V5, C1–C5, M1–M8），每个参数的评分如下：

准确度等级	得分/参数	判定标准
A 级（精确）	2 分	与实际值的相对误差 $\leq 20\%$
B 级（良好）	1.5 分	与实际值的相对误差 $\leq 30\%$
C 级（可接受）	0.5 分	与实际值的相对误差 $\leq 50\%$
D 级（不可接受）	0 分	误差 $> 50\%$ ，或未测量

参数实际值由助教统一标定，21 个参数满分 42 分。

5.3 报告质量（16 分）

评分项	分值	要求
µbench 设计思路	6 分	每个 µbench 有清晰的设计说明（测什么、怎么测、为什么这样设计），逻辑合理
测量数据分析	6 分	有原始数据、统计信息（均值/方差）、图表呈现，分析合理
报告结构与规范性	4 分	排版整洁、图表清晰

5.4 评分汇总

评分项	满分
µbench 完成度	42 分
参数测量准确度	42 分
报告质量	16 分
总分	100 分

6. 交付物

学号_姓名/	
└─ report.pdf	# 实验报告（含 µbench 设计思路、21 个参数测量结果、数据分析等）
└─ ubench/	# µbench 实现（源代码，每个 µbench 独立可运行）

交付格式：将上述目录压缩为 学号_姓名.zip，提交至教学网